

# VARIABLE SELECTION FOR REGRESSION MODELS

林扬涛

Email: 871636062@qq.com

School of Mathematical Sciences, South China Normal University

May 12, 2017

# CONTENTS

## 1 变量选择

- 模型
- $\beta, \gamma, \sigma^2$  的先验
- $\beta$  的后验
- $\gamma$  的后验
- $\sigma^2$  的后验
- 算法
- 实现

# 模型

## (广义)线性模型

$$\mathbf{y} \mid \boldsymbol{\beta}, \boldsymbol{\gamma}, \sigma^2 \sim \mathcal{N}_p(\mathbf{X}\boldsymbol{\vartheta}, \sigma^2 \mathbf{I}) \quad (1.1)$$

$\mathbf{Y} \in \mathcal{R}^{n \times 1}$ ,  $\mathbf{X} = [\mathbf{X}_1, \dots, \mathbf{X}_p] \in \mathcal{R}^{n \times p}$ ,  $\boldsymbol{\vartheta} = (\beta_1 \gamma_1, \dots, \beta_p \gamma_p)^T$ ,  
 $\boldsymbol{\beta}, \boldsymbol{\gamma}, \sigma^2$  都是未知参数。 $\sigma^2$  是一个标量。

# 似然函数

## 似然函数

$$\begin{aligned} f(\mathbf{y} \mid \boldsymbol{\beta}, \gamma, \sigma^2) &= \prod_{i=1}^n \left( \frac{1}{\sqrt{2\pi\sigma^2}} \right) \exp \left( -\frac{(\mathbf{y}_i - \mathbf{x}_i\boldsymbol{\vartheta})^2}{2\sigma^2} \right) \\ &= \left( \frac{1}{2\pi\sigma^2} \right)^{n/2} \exp \left( -\frac{(\mathbf{y} - \mathbf{X}\boldsymbol{\vartheta})^T (\mathbf{y} - \mathbf{X}\boldsymbol{\vartheta})}{2\sigma^2} \right) \end{aligned}$$

# 参数 $\beta, \gamma_j, \sigma^2$ 的先验

$\beta$ (多元高斯先验)

$$\beta \sim \mathcal{N}_p(\beta_0, D_0) \quad (1.2)$$

$\gamma_j$ (二项分布)

$$\gamma_j \sim B(1, p_j) \quad (1.3)$$

$\sigma^2$ (逆伽马分布)

$$\sigma^2 \sim \mathcal{IG}\left(\frac{\alpha}{2}, \frac{\eta}{2}\right) \quad (1.4)$$

# 参数 $\beta$ 的后验

## 多元高斯分布的一个重要性质

如果两组变量是联合高斯分布,那么一组变量为条件,另一组变量同样是高斯分布.类似地,任何一个变量的边缘分布也是高斯分布

# 参数 $\beta$ 的后验

- $\mathbf{y} \mid \beta \sim \mathcal{N}_p(\mu, \Sigma)$ , 其中  $\mu = \mathbf{X}^* \beta$ ,  $\Sigma = \sigma^2 I$ ,  $\mathbf{X}^* = [\gamma_1 \mathbf{x}_1, \dots, \gamma_1 \mathbf{x}_1]$
- $\beta \sim \mathcal{N}_p(\beta_0, D_0)$
- 贝叶斯定理 $\Rightarrow$

$$\begin{aligned} \ln p((\beta, \mathbf{y})^T) &= \ln(p(\mathbf{y} \mid \beta) \cdot p(\beta)) \\ &= \ln p(\mathbf{y} \mid \beta) + \ln p(\beta) \\ &= -\frac{1}{2}(\mathbf{y} - \mu)^T \Sigma^{-1}(\mathbf{y} - \mu) - \frac{1}{2}(\beta - \beta_0)^T D_0^{-1}(\beta - \beta_0) + C \end{aligned}$$

其中,常数 $C$ 表示与 $\mathbf{y}, \beta$ 无关的项.令 $z = (\beta, \mathbf{y})^T$ ,则上式为 $z$ 的分量的一个二次函数,因此 $p(z)$ 是一个高斯分布.为找到这个高斯分布的精度,我们考虑上式的前两项中的二次项.

参数 $\beta$ 的后验

$$\begin{aligned}
& -\frac{1}{2}\mathbf{y}^T\Sigma^{-1}\mathbf{y} + \frac{1}{2}\mathbf{y}^T\Sigma^{-1}\mu + \frac{1}{2}\mu^T\Sigma^{-1}\mathbf{y} - \frac{1}{2}\mu^T\Sigma^{-1}\mu - \frac{1}{2}\beta^T\mathbf{D}_0^{-1}\beta \\
& = -\frac{1}{2}\mathbf{y}^T\Sigma^{-1}\mathbf{y} + \frac{1}{2}\mathbf{y}^T\Sigma^{-1}\mathbf{X}^*\beta + \frac{1}{2}(\mathbf{X}^*\beta)^T\Sigma^{-1}\mathbf{y} - \frac{1}{2}(\mathbf{X}^*\beta)^T\Sigma^{-1}\mathbf{X}^*\beta - \frac{1}{2}\beta^T\mathbf{D}_0^{-1}\beta \\
& = -\frac{1}{2}\beta^T(\mathbf{D}_0^{-1} + \mathbf{X}^*\Sigma^{-1}\mathbf{X}^*)\beta - \frac{1}{2}\mathbf{y}^T\Sigma^{-1}\mathbf{y} + \frac{1}{2}\mathbf{y}^T\Sigma^{-1}\mathbf{X}^*\beta + \frac{1}{2}\beta^T\mathbf{X}^{*T}\Sigma^{-1}\mathbf{y} \\
& = \begin{pmatrix} \beta \\ \mathbf{y} \end{pmatrix}^T \begin{pmatrix} \mathbf{D}_0^{-1} + \mathbf{X}^*\Sigma^{-1}\mathbf{X}^* & -\mathbf{X}^{*T}\Sigma^{-1} \\ -\Sigma^{-1}\mathbf{X}^* & \Sigma^{-1} \end{pmatrix} \begin{pmatrix} \beta \\ \mathbf{y} \end{pmatrix} \\
& = \mathbf{z}^T R \mathbf{z}
\end{aligned}$$

其中 $R$ 为 $\mathbf{z}$ 上的高斯分布的精度矩阵(协方差的逆矩阵)



# 参数 $\beta$ 的后验

- 根据公式对 $R$ 求逆得

$$\text{cov}[z] = \begin{pmatrix} D_0 & D_0 \mathbf{X}^{*T} \\ \mathbf{X}^* D_0 & \sigma^2 I + \mathbf{X}^* D_0 \mathbf{X}^* \end{pmatrix}$$

- 根据条件高斯分布得 $\beta$ 的后验服从高斯分布

$$\beta \sim \mathcal{N}_p(\tilde{\beta}, D)$$

- 根据边缘高斯分布中条件概率的期望和方差得

$$\begin{aligned} \tilde{\beta} &= (D_0^{-1} + \sigma^{-2} \mathbf{X}^{*T} \mathbf{X}^*)^{-1} (D_0^{-1} \beta_0 + \sigma^{-2} \mathbf{X}^{*T} \mathbf{y}) \\ D &= (D_0^{-1} + \sigma^{-2} \mathbf{X}^{*T} \mathbf{X}^*)^{-1} \end{aligned}$$

# 参数 $\gamma_j$ 的后验

## 二项分布

$$\gamma_j \mid \gamma_{-j}, \beta, \sigma^2, \mathbf{y} \sim B(1, \tilde{p}_j) \quad (1.5)$$

- $\tilde{p}_j = c_j / (c_j + d_j)$
- $c_j = p_j \exp\{-\frac{1}{2\sigma^2}(\mathbf{y} - \mathbf{X}\boldsymbol{\vartheta}_j^*)^T(\mathbf{y} - \mathbf{X}\boldsymbol{\vartheta}_j^*)\}$
- $d_j = (1 - p_j) \exp\{-\frac{1}{2\sigma^2}(\mathbf{y} - \mathbf{X}\boldsymbol{\vartheta}_j^{**})^T(\mathbf{y} - \mathbf{X}\boldsymbol{\vartheta}_j^{**})\}$

其中 $\boldsymbol{\vartheta}_j^*$ 由 $\boldsymbol{\vartheta}$ 中第 $j$ 个数被 $\beta_j$ 替换得到

其中 $\boldsymbol{\vartheta}_j^{**}$ 由 $\boldsymbol{\vartheta}$ 中第 $j$ 个数被0替换得到

# 参数 $\sigma^2$ 的后验

## 二项分布

$$\begin{aligned}
 f(\sigma^2 \mid \mathbf{y}, \boldsymbol{\beta}, \gamma) &= f(\mathbf{y} \mid \sigma^2) f(\sigma^2) \\
 &\propto \left( \frac{1}{2\pi\sigma^2} \right)^{n/2} \exp \left( -\frac{(\mathbf{y} - \mathbf{X}\boldsymbol{\vartheta})^T (\mathbf{y} - \mathbf{X}\boldsymbol{\vartheta})}{2\sigma^2} \right) \mathcal{IG} \left( \frac{\alpha}{2}, \frac{\eta}{2} \right) \\
 &\propto (\sigma^2)^{-\frac{\alpha+n}{2}-1} \exp \left( \frac{\eta + (\mathbf{y} - \mathbf{X}\boldsymbol{\vartheta})^T (\mathbf{y} - \mathbf{X}\boldsymbol{\vartheta})}{2\sigma^2} \right)
 \end{aligned}$$

故

$$\sigma^2 \mid \mathbf{y}, \boldsymbol{\beta}, \gamma \sim \mathcal{IG} \left( \frac{\alpha + n}{2}, \frac{\eta + (\mathbf{y} - \mathbf{X}\boldsymbol{\vartheta})^T (\mathbf{y} - \mathbf{X}\boldsymbol{\vartheta})}{2} \right)$$

# 算法

## SSVS2

- ① 初始化:  $\beta_0, D_0, \gamma, \alpha, \eta, p_j$
- ② 迭代: for  $t=1, 2, \dots$ 
  - 存储  $\beta$
  - 存储  $\gamma$
  - 存储  $\sigma^2$
- ③ 统计  $\gamma$

# 实现

示例

$$\mathbf{y} = \mathbf{x}_4 + 1.2\mathbf{x}_5 + \epsilon \quad (1.6)$$

其中  $\epsilon \sim \mathcal{N}_{60}(0, \sigma^2 I), \sigma = 2.5$