

# BAYESIAN VARIABLE SELECTION —— STOCHASTIC SEARCH VARIABLE SELECTION

Dom Tsang

Email: 395091490@qq.com

School of Mathematical Sciences, South China Normal University

May 11, 2017

# CONTENTS

- 1 前情回顾
- 2 Stochastic Search Variable Selection(随机搜索变量选择)
- 3 算法
- 4 模型选择
- 5 参考文献

# CONTENTS

## 1 前情回顾

## 2 Stochastic Search Variable Selection(随机搜索变量选择)

## 3 算法

## 4 模型选择

## 5 参考文献

## ■ 变量选择

## ■ 分层贝叶斯框架

# 变量选择

## ■ 一范数约束




Figure 1: 正则化限制区域

机器学习中的范数规则化之(一)L0、L1 与 L2 范数

http:

//blog.csdn.net/zouxy09/article/details/24971995

逐步回归

# 分层贝叶斯模型示例

- 模型:  $\mathbf{y}_{(P,1)} = \mathbf{H}_{(P,M)}\mathbf{x}_{(M,1)} + \mathbf{n}_{(P,1)}$  其中,  $\mathbf{n} \sim \mathcal{N}(0, \sigma^2 \mathbf{I}_p)$
- 似然函数:  $f(\mathbf{y}|\mathbf{x}, \sigma^2) = \left(\frac{1}{2\pi\sigma^2}\right)^{P/2} \exp\left(-\frac{\|\mathbf{y}-\mathbf{H}\mathbf{x}\|^2}{2\sigma^2}\right)$
- 参数先验:  $f(\mathbf{x}|w, a) = [(1-w)^{n_0} \prod_{i \in \mathcal{I}_0} \delta(x_i)] [w^{n_1} \prod_{i \in \mathcal{I}_1} g_a(x_i)]$   
 $\sigma^2 | \nu, \gamma \sim \mathcal{IG}(\frac{\nu}{2}, \frac{\gamma}{2})$
- 超参数的先验:  $a | \alpha \sim \mathcal{IG}(\alpha_0, \alpha_1)$   
 $w \sim \mathcal{U}([0, 1])$   
 $f(\gamma) \propto \frac{1}{\gamma}$
- 参数后验:  $w | \mathbf{x} \sim \mathcal{BE}(1 + n_1, 1 + n_0)$   
 $a | \mathbf{x}, \alpha_0, \alpha_1 \sim \mathcal{IG}(\|\mathbf{x}\|_0 + \alpha_0, \|\mathbf{x}\|_1 + \alpha_1)$   
 $f(x_i | w, a, \sigma^2, \mathbf{x}_{-i}, \mathbf{y}) \propto (1 - w_i) \delta(x_i) + w_i \phi_+(x_i | \mu_i, \eta_i^2)$   
 $\sigma^2 | \mathbf{x}, \mathbf{y} \sim \mathcal{IG}(\frac{P}{2}, \frac{\|\mathbf{y}-\mathbf{H}\mathbf{x}\|^2}{2})$

# 算法

## ■ 初始化

← 从先验中

1 随机生成  $\mathbf{x}^{(0)}$

2 随机生成  $\sigma^{(0)}$

## ■ 循环: for $t = 1, 2, \dots$ , do:

1 随机生成  $w^{(t)}$

2 随机生成  $a^{(t)}$

3 For  $i = 1, \dots, M$

随机生成  $x_i^{(t)}$

← 从后验中

4 随机生成  $\sigma^{2(t)}$

5  $t \leftarrow t+1$

# CONTENTS

## 1 前情回顾

## 2 Stochastic Search Variable Selection(随机搜索变量选择)

## 3 算法

## 4 模型选择

## 5 参考文献

### ■ 模型

### ■ $\beta$ 的先验

### ■ $\gamma$ 的先验

### ■ $\sigma^2$ 的先验

### ■ $\beta$ 的后验

### ■ $\gamma$ 的后验

### ■ $\sigma^2$ 的后验

# 模型

## (广义) 线性模型

$$\mathbf{Y}|\boldsymbol{\beta}, \sigma^2 \sim \mathcal{MVN}(\mathbf{X}\boldsymbol{\beta}, \sigma^2 \mathbf{I}) \quad (2.1)$$

其中,  $\mathbf{Y} \in \mathcal{R}^n$ ,  $\mathbf{X} \in \mathcal{R}^{n \times p}$ ,  $\boldsymbol{\beta} = (\beta_1, \dots, \beta_p)^\top$ ,  $\sigma^2$  是一个标量.  $\boldsymbol{\beta}$  和  $\sigma^2$  都是未知参数.

\*  $\mathcal{MVN}(\mathbf{X}\boldsymbol{\beta}, \sigma^2 \mathbf{I})$  即是通常的正态分布  $\mathcal{N}(\mathbf{X}\boldsymbol{\beta}, \sigma^2 \mathbf{I})$

\* 式 (2.1) 的意思是  $\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{n}$ , 其中  $\mathbf{n} \sim \mathcal{N}(0, \sigma^2 \mathbf{I})$



## $\beta$ 的先验

- 使用两个不同方差的高斯分布的混合分布对  $\beta$  的每个成分进行建模. 引入隐变量  $\gamma_i = 0$  或  $1$ , 可将高斯分布混合成,

$\beta_i$  (混合高斯)

$$\beta_i | \gamma_i \sim (1 - \gamma_i) \mathcal{N}(0, \tau_i^2) + \gamma_i \mathcal{N}(0, c_i^2 \tau_i^2) \quad (2.2)$$

$$P(\gamma_i = 1) = 1 - P(\gamma_i = 0) = \omega_i \quad (2.3)$$

\* 式 (8) 表达的模型用大家相对熟悉的表达形式即是

$$\begin{aligned} P(\beta_i) &= P(\gamma_i = 0)P(\beta_i | \gamma_i = 0) + P(\gamma_i = 1)P(\beta_i | \gamma_i = 1) \\ &= (1 - \omega_i) \mathcal{N}(0, \tau_i^2) + \omega_i \mathcal{N}(0, c_i^2 \tau_i^2) \end{aligned}$$

## $\beta$ 的先验

### $\beta$ (多元高斯先验)

$$\beta|\gamma \sim \mathcal{MVN}(0, \mathbf{D}_\gamma \mathbf{R} \mathbf{D}_\gamma) \quad (2.4)$$

其中  $\gamma = (\gamma_1, \dots, \gamma_p)^\top$ ,  $\mathbf{R}$  是先验协方差矩阵,  
 $\mathbf{D}_\gamma = \text{diag}[\{d_i\}_{i=1}^p]$ , 其中  $d_i = (1 - \gamma_i)\tau_i + \gamma_i c_i \tau_i$ .

# $\gamma$ 的先验

$\gamma$  (二项分布)

$$\gamma \sim \prod_{i=1}^p \omega_i^{\gamma_i} (1 - \omega_i)^{1 - \gamma_i} \quad (2.5)$$

# $\sigma^2$ 的先验

$\sigma^2$ (逆 gamma 分布)

$$\sigma^2 | \gamma \sim \text{IG}\left(\frac{\nu_\gamma}{2}, \frac{\nu_\gamma \lambda_\gamma}{2}\right) \quad (2.6)$$

## $\beta$ 的后验

### $\beta$ 的后验

$$\begin{aligned}\beta^{(j)} &\sim f(\beta^{(j)} | \mathbf{Y}, \sigma^{2(j-1)}, \gamma^{j-1}) \\ &= \mathcal{MVN}(A_{\gamma^{j-1}}(\sigma^{j-1})^{-2} \mathbf{X}^\top \mathbf{Y}, A_{\gamma^{j-1}})\end{aligned}\quad (2.7)$$

其中,  $A_{\gamma^{j-1}} = ((\sigma^{j-1})^{-2} \mathbf{X}^\top \mathbf{X} + \mathbf{D}_{\gamma^{j-1}}^{-1} \mathbf{R}^{-1} \mathbf{D}_{\gamma^{j-1}}^{-1})$ .

## $\sigma^2$ 的后验

### $\sigma^2$ 的后验

$$\begin{aligned}\sigma^{2(j)} &\sim f(\sigma^{2(j)} | \mathbf{Y}, \boldsymbol{\beta}^j, \gamma^{j-1}) \\ &= \mathcal{IG}\left(\frac{n + \nu_{\gamma^{j-1}}}{2}, \frac{|\mathbf{Y} - \mathbf{X}\boldsymbol{\beta}^j|^2 + \nu_{\gamma^{j-1}}\lambda_{\gamma^{j-1}}}{2}\right)\end{aligned}\quad (2.8)$$

## $\gamma$ 的后验

$$\gamma_i^j \sim f(\gamma_i^j | \mathbf{Y}, \boldsymbol{\beta}^j, \sigma^{2(j)}, \gamma_{(\neq i)}^j) = f(\gamma_i^j | \boldsymbol{\beta}^j, \sigma^{2(j)}, \gamma_{(\neq i)}^j) \quad (2.9)$$

每一个伯努利分布的概率为:

$$P(\gamma_i^j = 1 | \boldsymbol{\beta}^{(j)}, \sigma^{2(j)}, \gamma_{(\neq i)}^{(j)}) = \frac{a}{a + b} \quad (2.10)$$

其中,

$$a = f(\boldsymbol{\beta}^{(j)} | \gamma_{(\neq i)}^{(j)}, \gamma_{(i)}^{(j)} = 1) f(\sigma^{2(j)} | \gamma_{(\neq i)}^{(j)}, \gamma_{(i)}^{(j)} = 1) f(\gamma_{(\neq i)}^{(j)}, \gamma_{(i)}^{(j)} = 1) \quad (2.11)$$

$$b = f(\boldsymbol{\beta}^{(j)} | \gamma_{(\neq i)}^{(j)}, \gamma_{(i)}^{(j)} = 0) f(\sigma^{2(j)} | \gamma_{(\neq i)}^{(j)}, \gamma_{(i)}^{(j)} = 0) f(\gamma_{(\neq i)}^{(j)}, \gamma_{(i)}^{(j)} = 0) \quad (2.12)$$

# $\gamma$ 的后验

当  $\sigma$  的先验参数为常数时 ( $\nu_\gamma \equiv \nu, \lambda_\gamma \equiv \lambda$ ), 式2.11, 2.12可进一步简化为

$$\begin{aligned} a &= f(\beta^{(j)} | \gamma_{(\neq i)}^{(j)}, \gamma_{(i)}^{(j)} = 1) f(\gamma_{(\neq i)}^{(j)}, \gamma_{(i)}^{(j)} = 1) \\ &= f(\beta^{(j)} | \gamma_{(\neq i)}^{(j)}, \gamma_{(i)}^{(j)} = 1) \omega_i \end{aligned} \quad (2.13)$$

$$\begin{aligned} b &= f(\beta^{(j)} | \gamma_{(\neq i)}^{(j)}, \gamma_{(i)}^{(j)} = 0) f(\gamma_{(\neq i)}^{(j)}, \gamma_{(i)}^{(j)} = 0) \\ &= f(\beta^{(j)} | \gamma_{(\neq i)}^{(j)}, \gamma_{(i)}^{(j)} = 0) (1 - \omega_i) \end{aligned} \quad (2.14)$$



# 算法

## SSVS

- 1 初始化:  $\beta^0, \sigma^2, \gamma, \mathbf{c}, \tau, \mathbf{R}, \omega, \nu, \lambda$
- 2 迭代: for  $t = 1, 2, \dots$ :
  - 从式2.7中抽取  $\beta$ ;
  - 从式2.8中抽取  $\sigma^2$ ;
  - 从式2.10中抽取  $\gamma$ .

# CONTENTS

## 1 前情回顾

## 2 Stochastic Search Variable Selection(随机搜索变量选择)

## 3 算法

## 4 模型选择

## 5 参考文献

### ■ 问题描述

### ■ 模型空间

### ■ 模型的量化表示

### ■ 模型的后验概率估计

## 问题描述

- 问题: 从模型集合中选择一个最优模型
- 在贝叶斯框架中, 模型选择问题被转化为参数估计的形式而不是寻找单一的最优模型, 贝叶斯方法将估计所有模型的后验概率. 在很多情况下, 这个问题从变量的层面被提出: 例如, 估计模型中变量的边缘后验概率.

## 模型空间

在模型选择中, 模型空间的均匀分布被定义成:

$$f(m) = \frac{1}{|\mathcal{M}|}, \text{ for all } m \in \mathcal{M} \quad (4.1)$$

## 模型的量化表示

- $\gamma$  的向量空间与模型空间建立起一个一一对应的映射:

$$m(\gamma) = \sum_{j=k}^p \gamma_j 2^{j-k} \quad (4.2)$$

## 模型的后验概率

$$\hat{f}(m|\mathbf{Y}) = \frac{1}{T-B} \sum_{t=B+1} I(m^{(t)} = m) \quad (4.3)$$

其中,  $T$  和  $B$  分别是算法总共的迭代次数和预模拟运行 (burnin) 的迭代次数,  $m^{(t)}$  是模型在迭代次数  $t$  下的指示值.

## Reference



O'Hara R B, Sillanpaa M J. A review of Bayesian variable selection methods: what, how and which[J]. Bayesian analysis, 2009, 4(1): 85-117.



George E I, McCulloch R E. Variable selection via Gibbs sampling[J]. Journal of the American Statistical Association, 1993, 88(423): 881-889.

# Thanks!